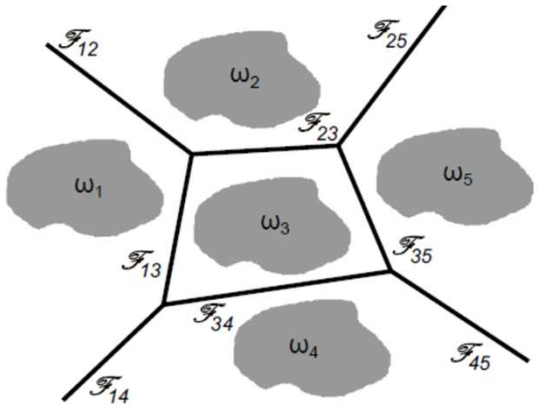
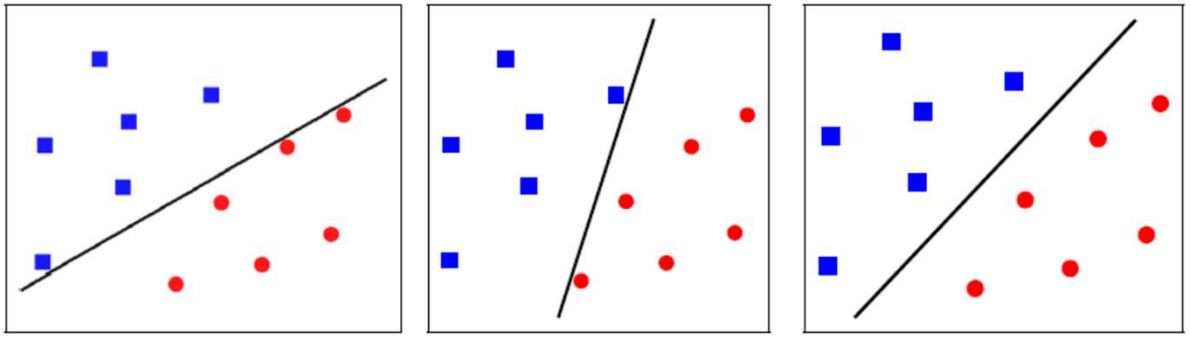
Metódy detekcie anomálií – klasifikácia do jednej triedy – (normálne data)

- Prahovanie (sledujú sa rôzne veličiny a stanovia sa prahy na detekciu anomálií)
- One-Class Support Vector Machine (SVM iba pre normálne data, sleduje sa skóre na klasifikáciu do triedy, malé skóre signalizuje anomáliu)
- Isolation Forest (algoritmus náhodných stromov izoluje rozhodovanie až na úroveň listu, ak je hĺbka rozhodovacieho stromu väčšia ako priemerná na trénovacích dátach ide o anomáliu.
- Autoencoder – hlboká sieť

# Mechanizmy podporných vektorov (Support vector machines)



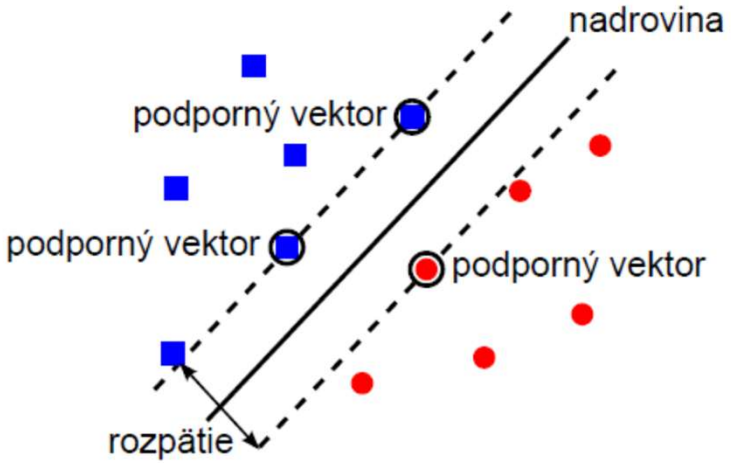
(a) Nadrovina príliš blízko trénovacích dát. (b) Nadrovina príliš blízko trénovacích dát. (c) Nadrovina dostatočne d'aleko od trénovacích dát.

**Lineárny klasifikátor** – dobre klasifikuje trénovacie data, na testovacích vykazuje veľkú chybovosť, riešením je nájdenie nadroviny dostatočne vzdialené od trénovacích dát

Počítačové videnie, Elena Šikudová Zuzana Cernekova Wanda Benešová, **chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://cgg.mff.cuni.cz/wp-content/uploads/2021/10/strukturovana_kniha_CD_noveISBN.pdf**

# Mechanizmy podporných vektorov (Support vector machines)

**Podporné vektory** – sú tie vzorky každej triedy ktoré sú najbližšie k rozdelujúcej nadrovine. Vzdialenosť medzi podpornými vektormi rôznych tried nazývame rozpätie. Úlohou je nájsť takú nadrovinu, aby sa maximalizovalo toto rozpätie.




Rozpätie je $\frac{2}{\|\mathbf{w}\|}$.

Optimalizačná úloha

$$\mathbf{w}^* = \arg\max \frac{2}{\|\mathbf{w}\|}.$$

Riešenie je pomocou Lagrangeovej metódy neurčitých koeficientov (derivácia Lagrangiánu, Kuhn Tuckerove podmienky)

$$(\mathbf{w}^*, b^*) = \arg\min \frac{1}{2}\|\mathbf{w}\|^2,$$

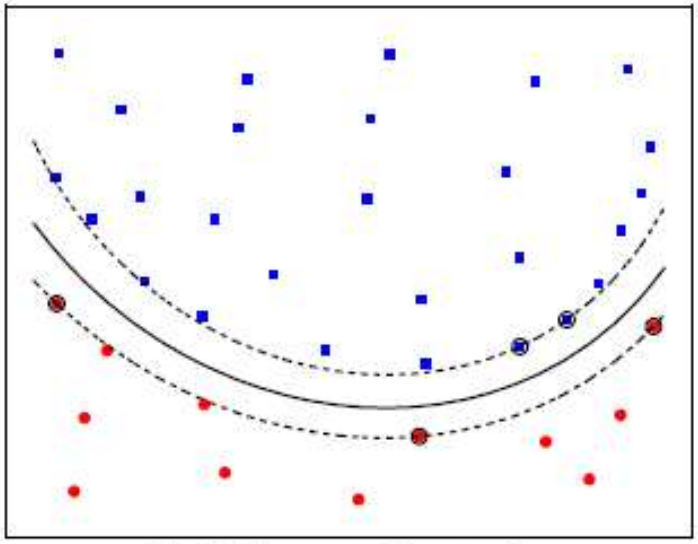
aby

$$\mathbf{w}^T\mathbf{x}_i + b \geq 1 \text{ pre } \mathbf{x} \in \omega_1,$$

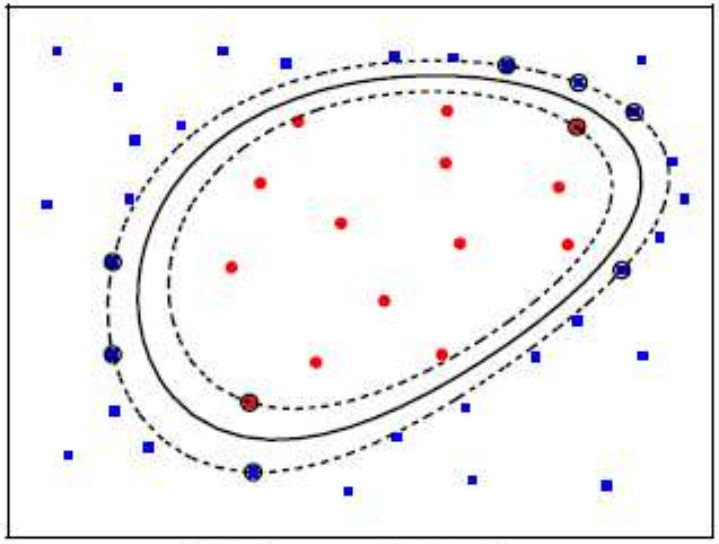
$$\mathbf{w}^T\mathbf{x}_i + b \leq -1 \text{ pre } \mathbf{x} \in \omega_2.$$

# Mechanizmy podporných vektorov (Support vector machines)

**Nelineárne Podporné vektory** – použitie Polynomiálneho alebo Gausovského kernelovho jadra.



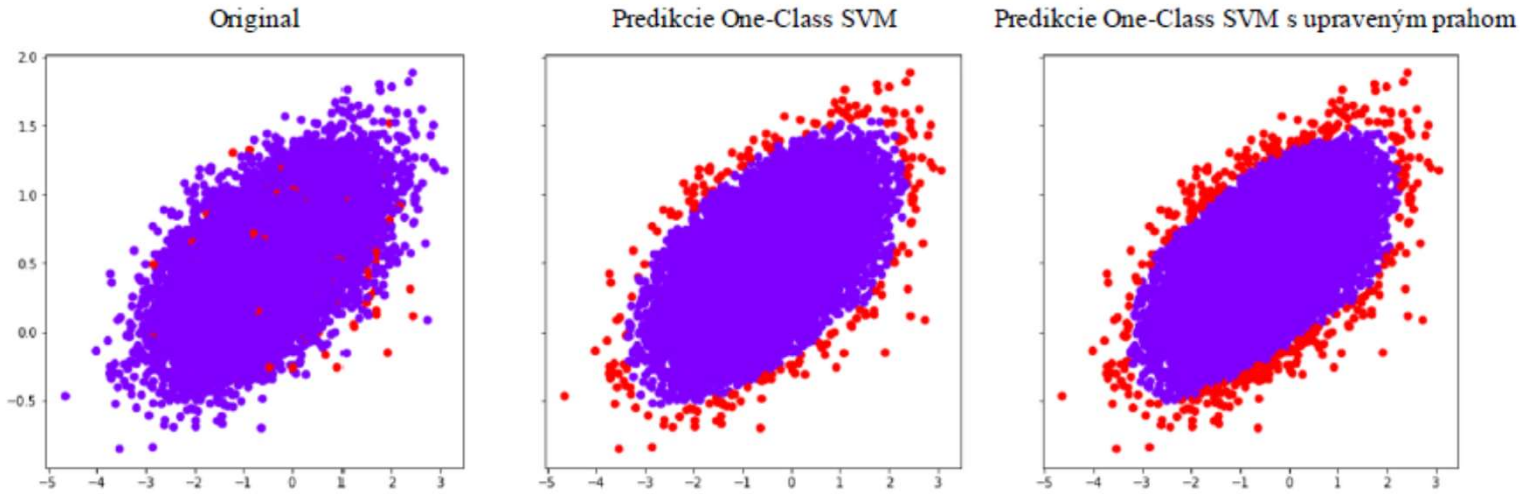
(a) Polynomiálne jadro.



(b) Gausovské jadro.

# One-class SVM

**OCSVM** – SVM prispôsobená na detekciu anomálií, učí sa na normálnych dátach a snaží sa nájsť hranicu (hyperplochu), ktorá oddeľuje normálne vzorky od zvyšku priestoru.

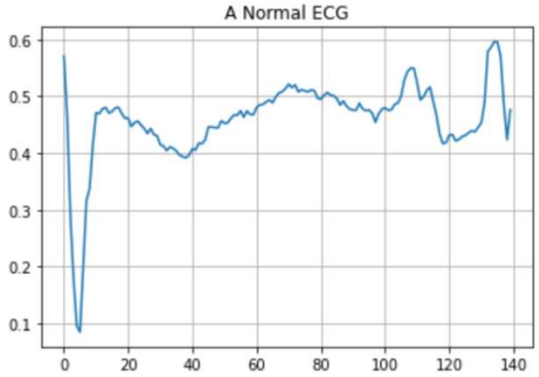


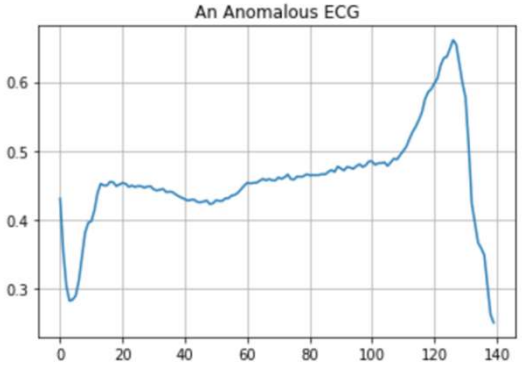

Vizualizácia detekcie anomálií pomocou OCSVM

**Výhody:** efektívna na malé a stredné datasety, rieši aj nelineárne závislosti
**Nevýhody:** pri väčších datasetoch výpočtovo náročnejšia, potreba ladenia parametrov

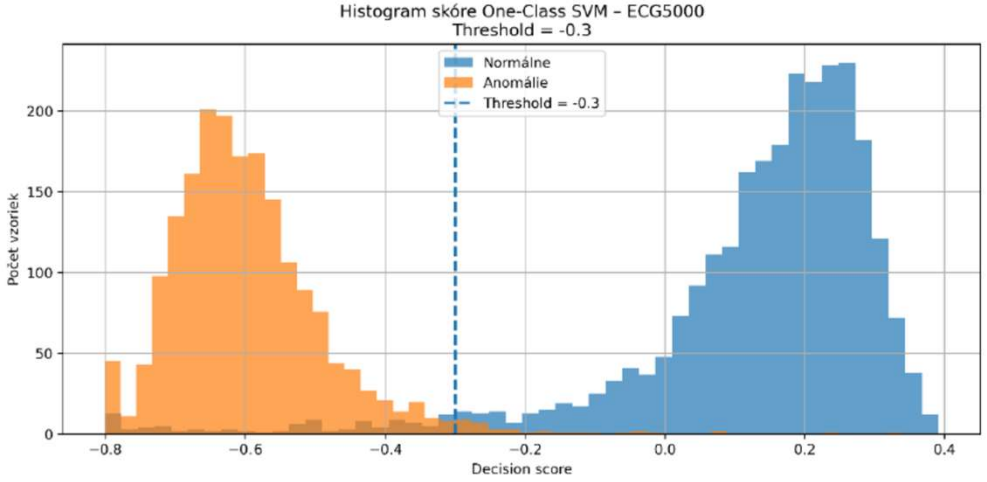
# One-class SVM

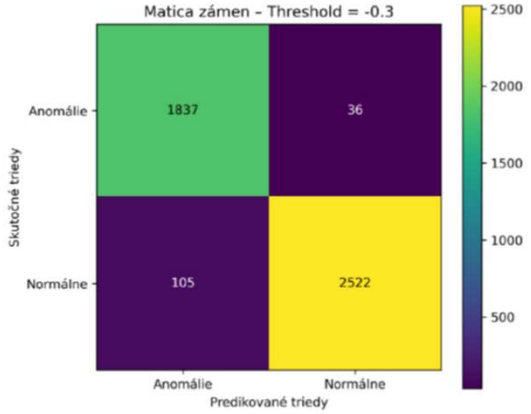
**Príklad detekcie anomálie – Dataset ECG5000** (EKG normálne a patologické záznamy, vyrezané okná jedného úderu srdca)



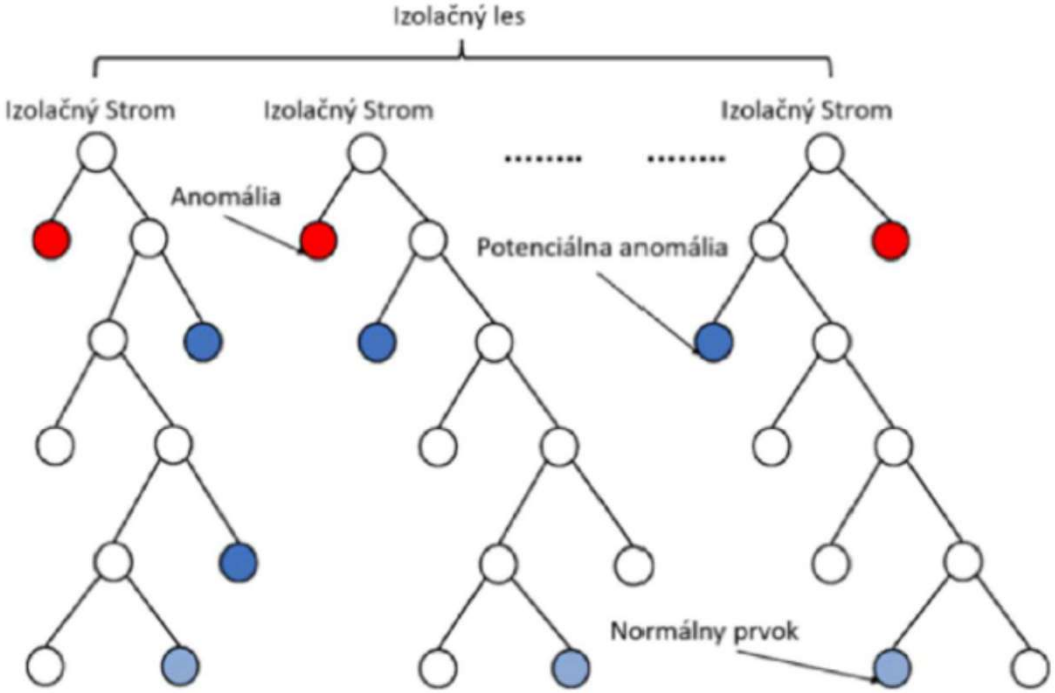

| *Threshold* | Accuracy % | Precision % | Recall % | F1-score % |
|---|---|---|---|---|
| 0.0 | 91.53 | 83.21 | 99.79 | 90.75 |
| -0.3 | 96.87 | 94.59 | 98.08 | 96.3 |
| -0.5 | 92.64 | 96.78 | 85.16 | 90.6 |



# Izolačný les
# (Isolation Forest)

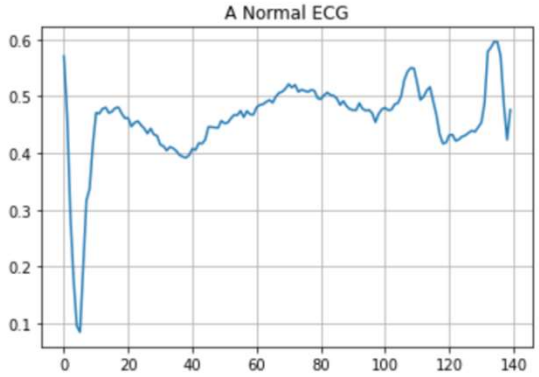
- **IF** – algoritmus ML určený najmä na detekciu anomálií – teda objektov, ktoré sa výrazne líšia od ostatných
- Anomálie potrebujú menej krokov, aby boli izolované → kratšia cesta v strome.
- Výsledkom je skóre anomálie.

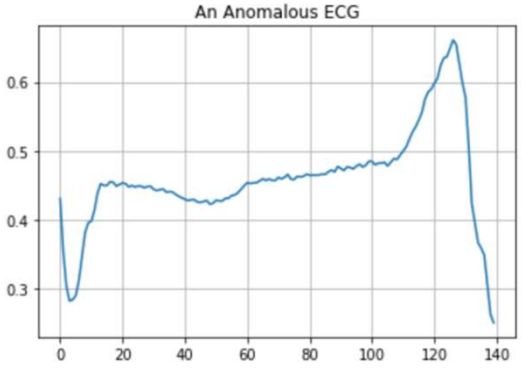



Počítačové videnie, Elena Šikudová Zuzana Cernekova Wanda Benešová, **chrome-extension://efaidnbmnnnibpcajpcglclefindmkaj/https://cgg.mff.cuni.cz/wp-content/uploads/2021/10/strukturovana_kniha_CD_noveISBN.pdf**

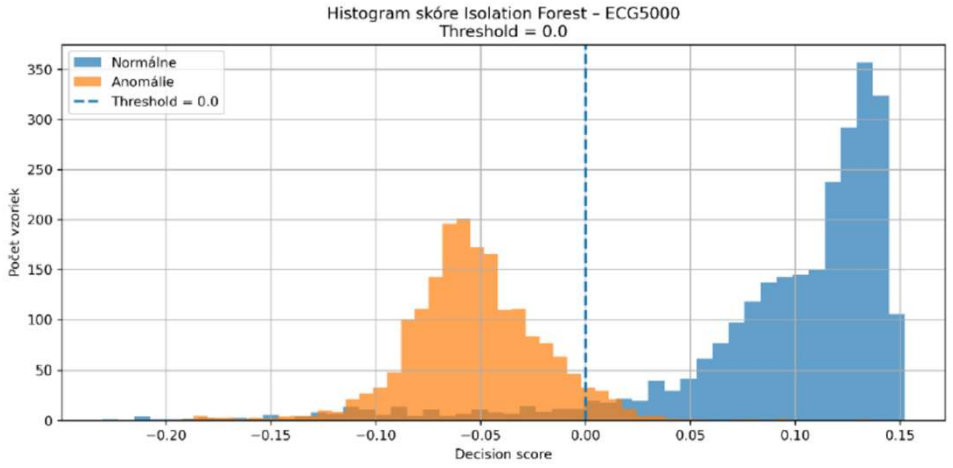
# Isolation Forest

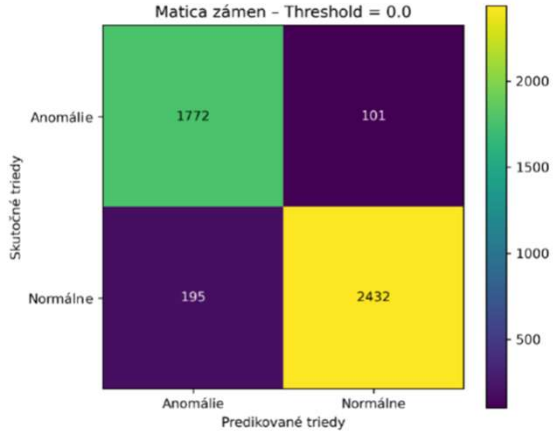
**Príklad detekcie anomálie – Dataset ECG5000** (EKG normálne a patologické záznamy, vyrezané okná jedného úderu srdca)



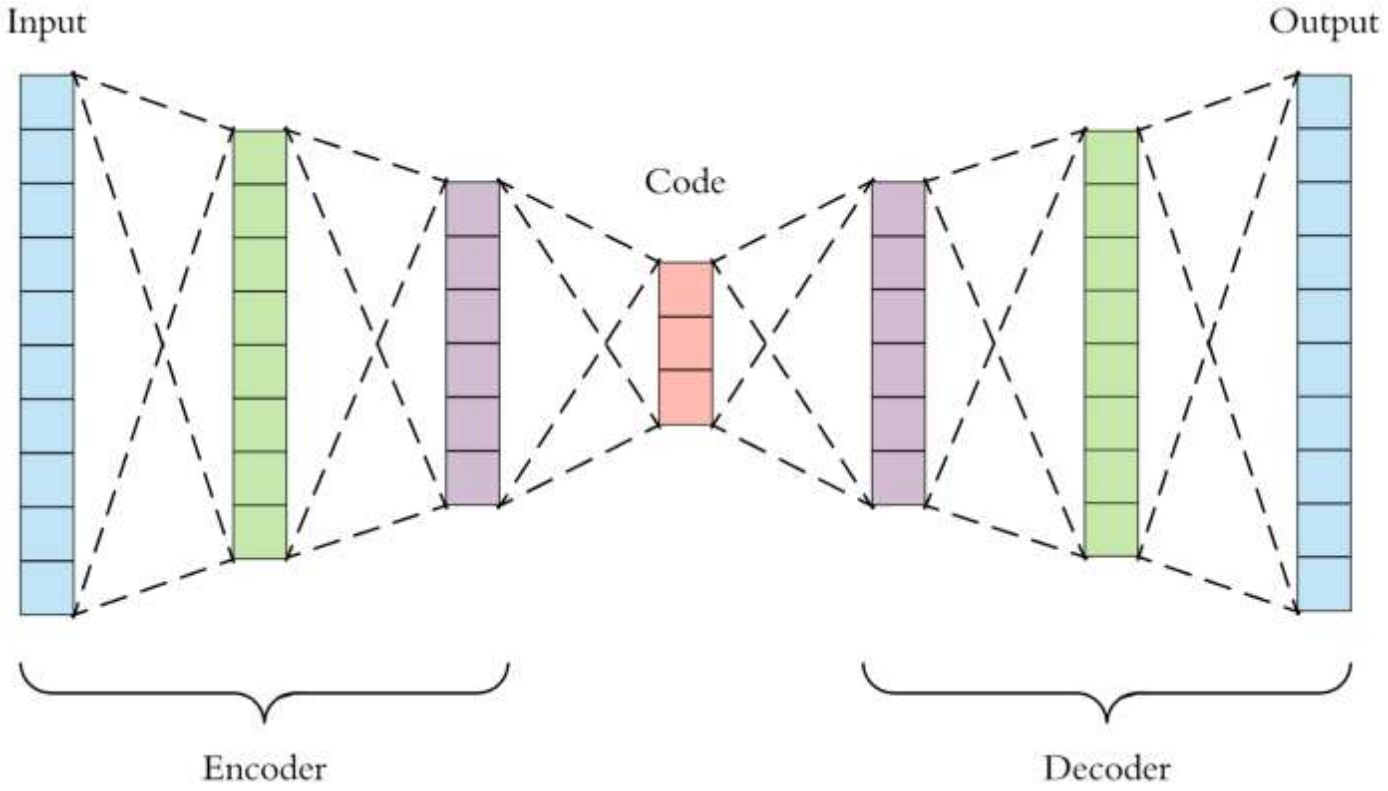

| *Threshold* | Accuracy % | Precision % | Recall % | F1-score % |
|---|---|---|---|---|
| 0.0 | 93.42 | 90.09 | 94.61 | 92.29 |
| 0.025 | 93.84 | 87.78 | 98.99 | 93.05 |
| 0.05 | 91.62 | 83.42 | 99.68 | 90.83 |



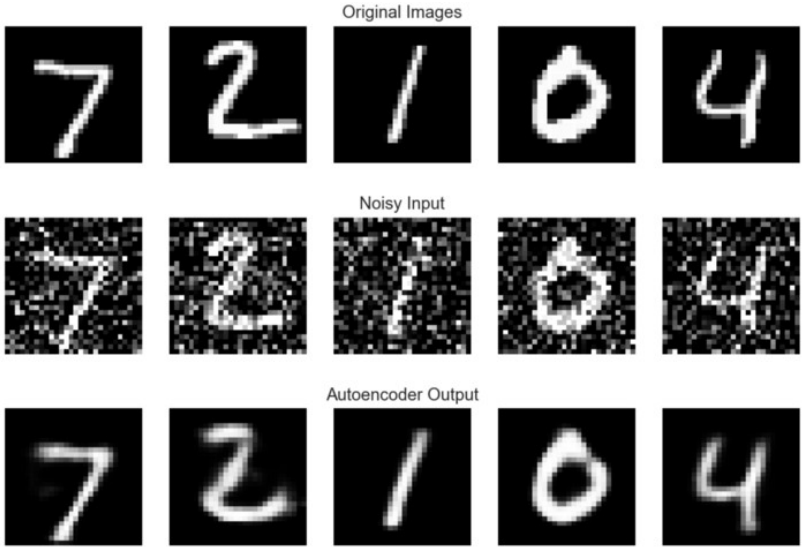
# Autoenkódery

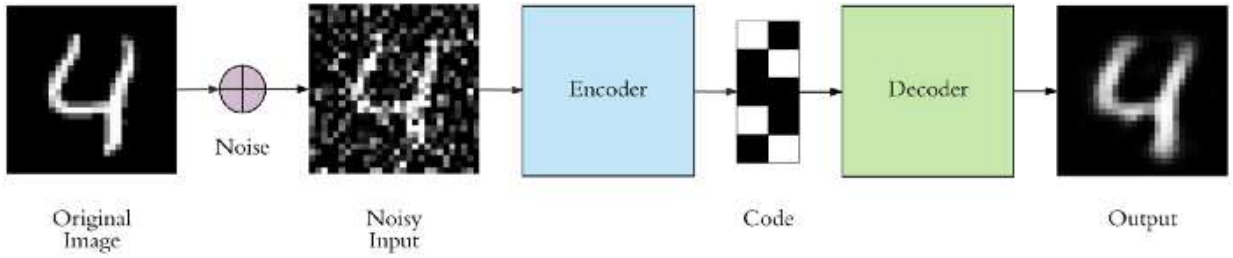
- Časti – enkóder, zakódovaný vstup, dekóder
- Učenie bez učiteľa (nepotrebuje predkladaný vzor)
- Kompresia, redukcia vstupu
- Učenie backpropagation
- Vstupný aj výstupný obraz je rovnaký
- Nie je cieľom, aby autoenkóder bez chyby dekódoval vzor

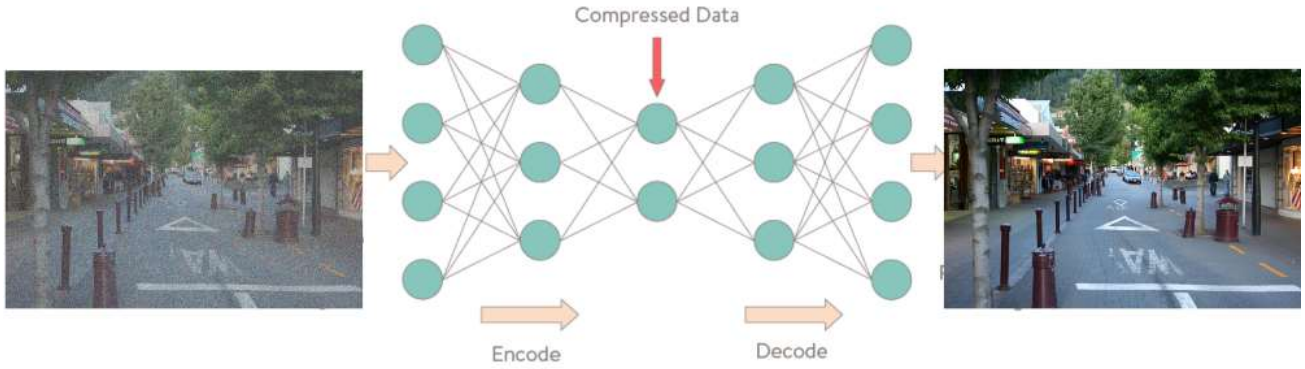



https://towardsdatascience.com/applied-deep-learning-part-3-autoencoders-1c083af4d798

# Odšumenie obrazu autoenkóderom

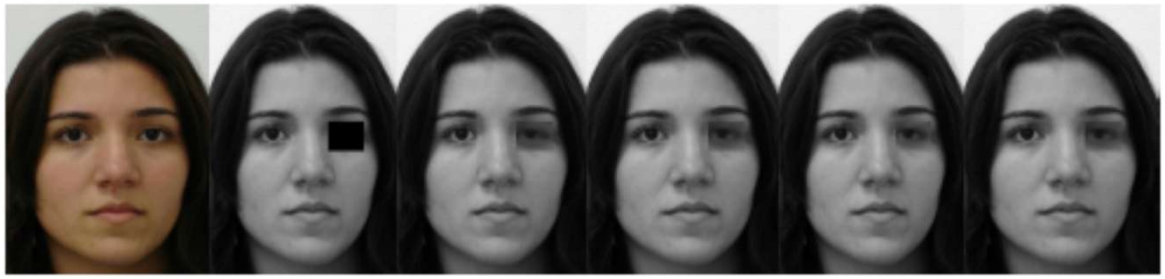


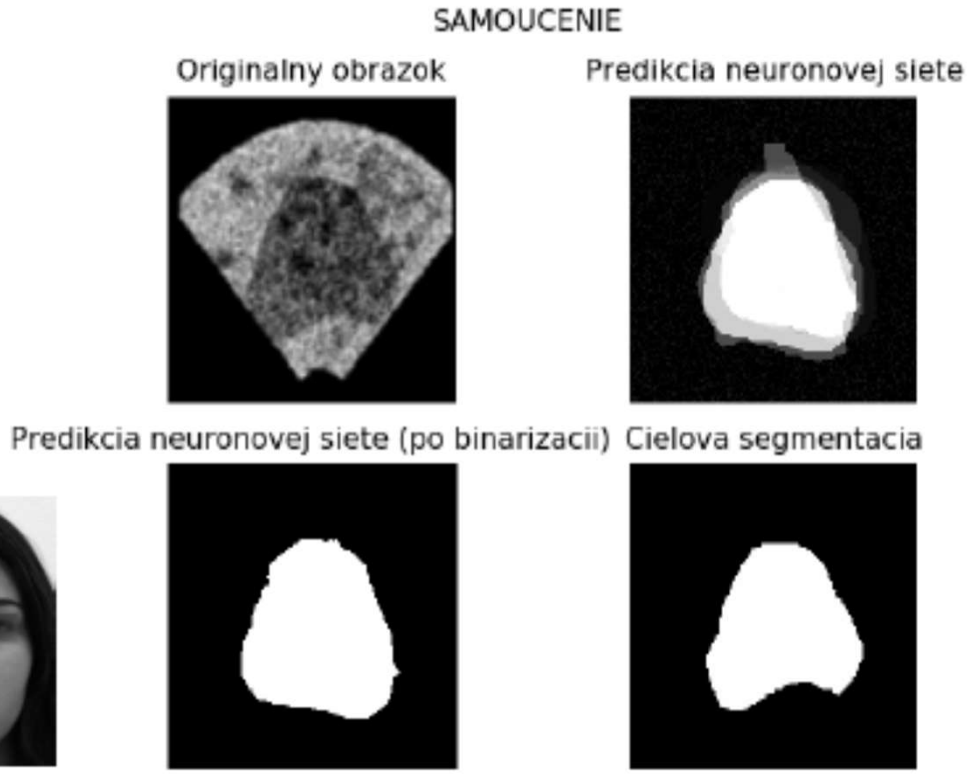




https://towardsdatascience.com/applied-deep-learning-part-3-autoencoders-1c083af4d798

- Obraz v obraze – dopočítanie chýbajúceho obrazu
- Segmentácia obrazu – detekcia nádoru, orgánov na snímkoch

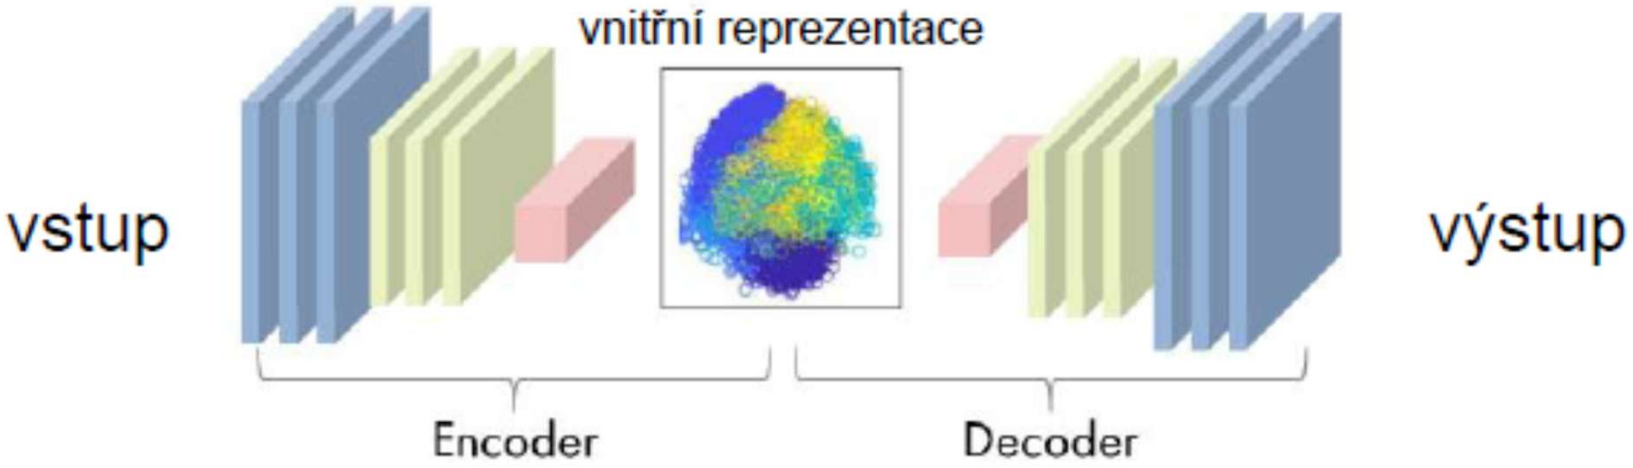




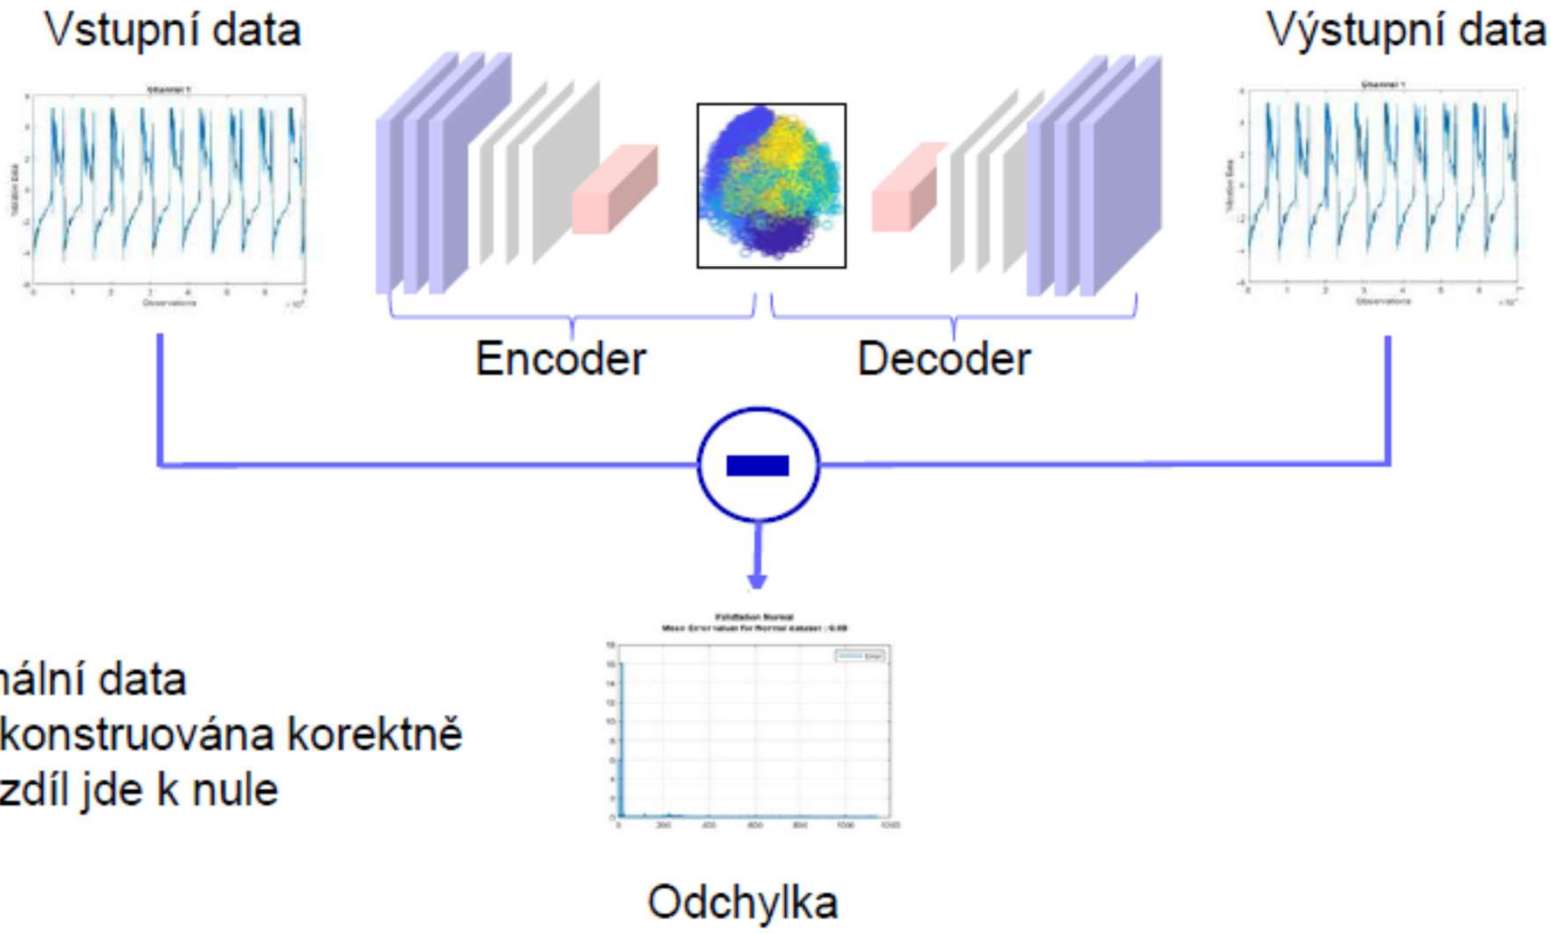

https://towardsdatascience.com/applied-deep-learning-part-3-autoencoders-1c083af4d798

## Detekcia anomálií – Autoencoder – klasifikácie pre normálne data

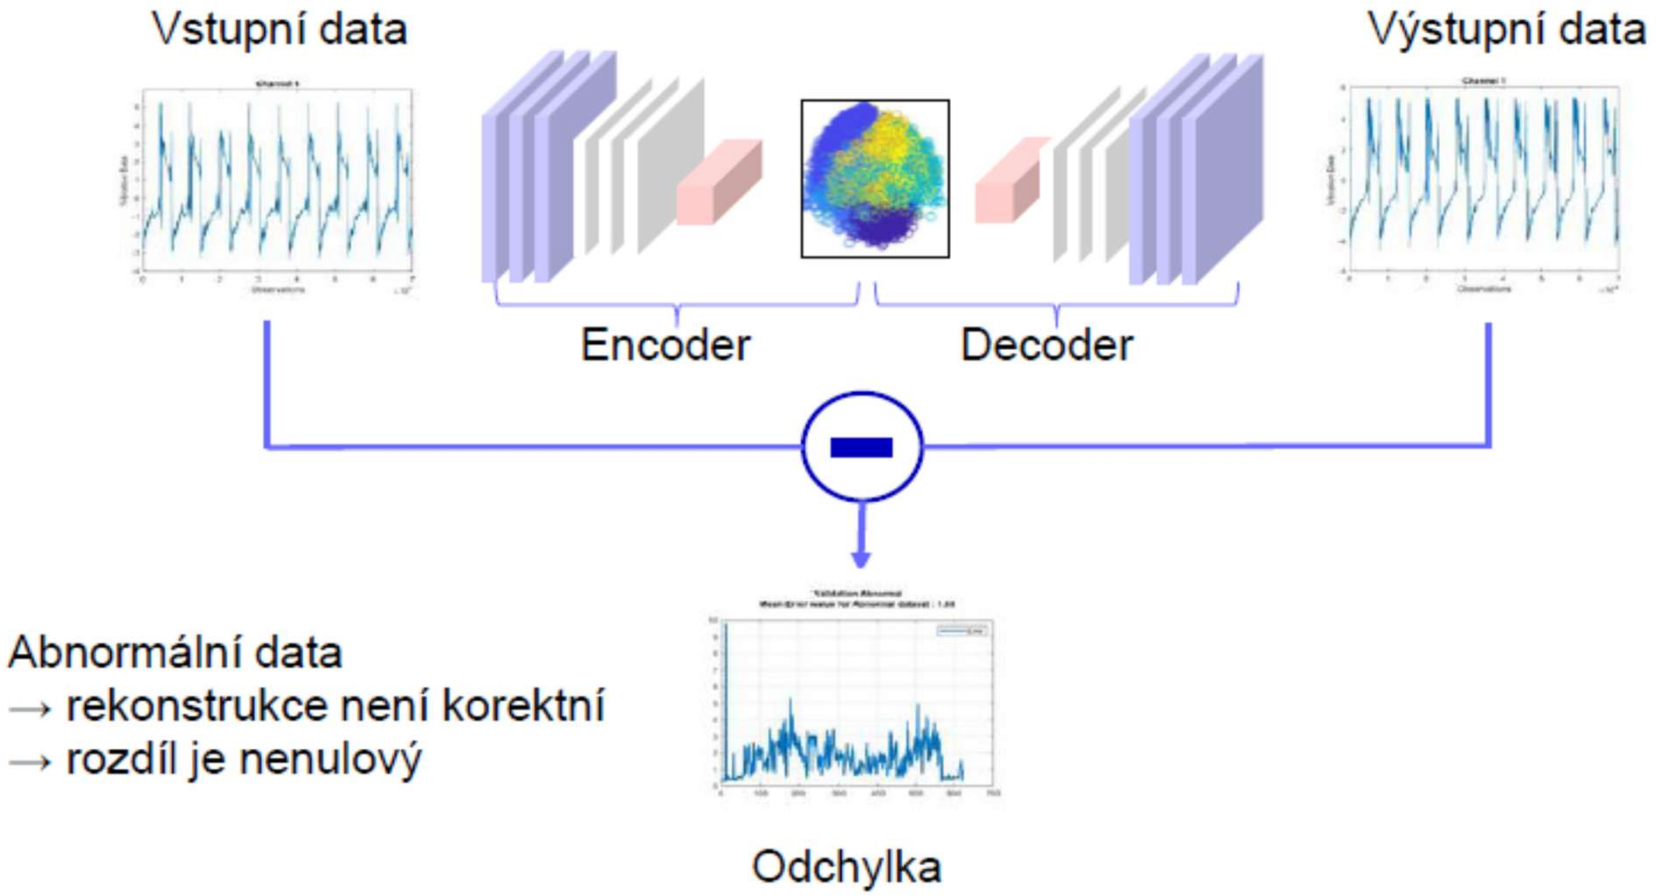
- Hlboká sieť zložená z dvoch častí: encoder, decoder
- Učenie siete prebieha iba na normálnych dátach, kde cieľom je rekonštruovať pôvodné data, pre normálne data sa odchýlka sa blíži k nule (malá)
- Veľká odchýlka pri rekonštrukcii signálu, signalizuje anomáliu



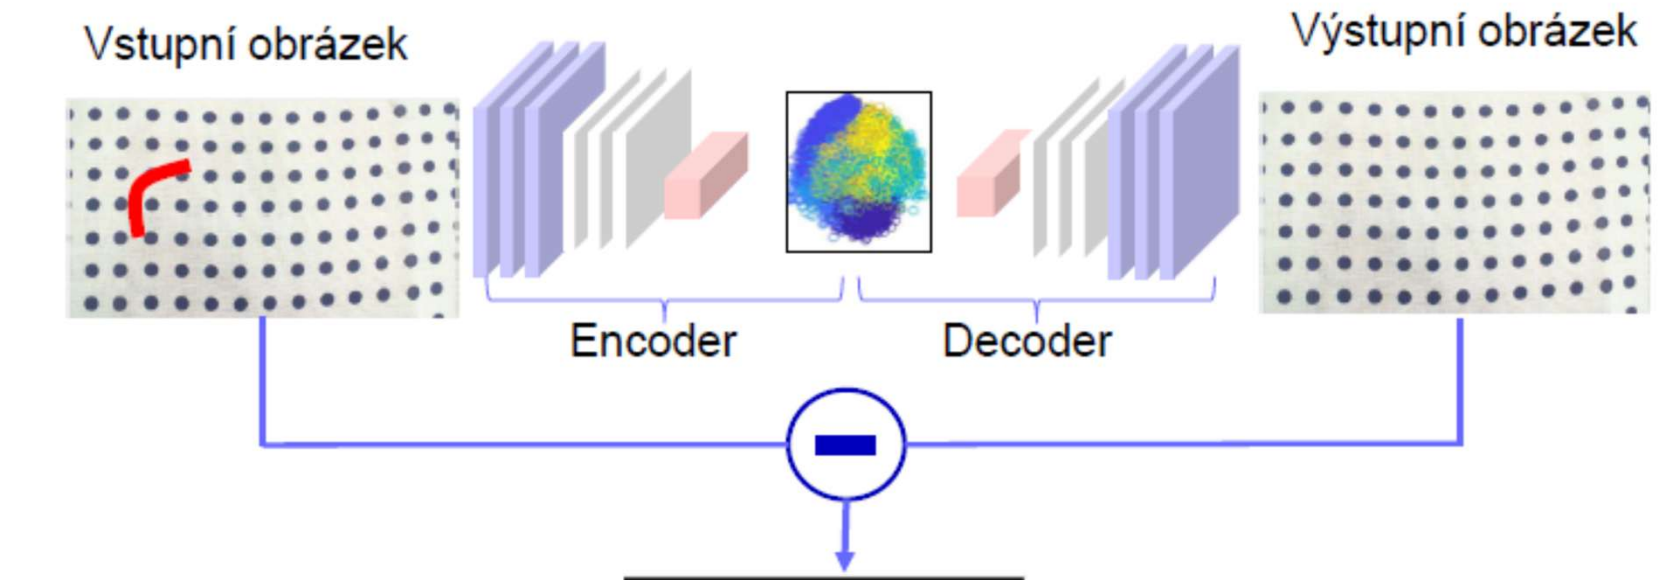
# Detekcia anomálií – Autoencoder – nasadenie autoenkodera - normálne data



# Detekcia anomálií – Autoencoder – nasadenie autoenkodera – abnormálne data



# Detekcia anomálií – nasadenie autoenkodera – abnormálne obrazové data

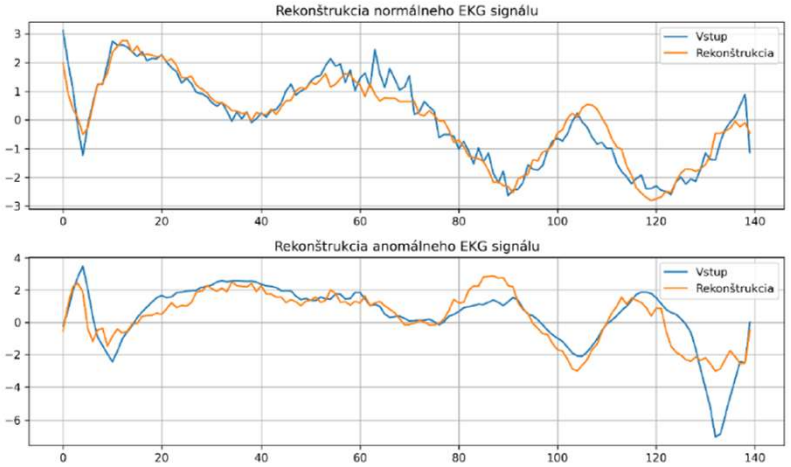



Normální obrázek
→ rekonstruován korektně
→ rozdíl jde k nule

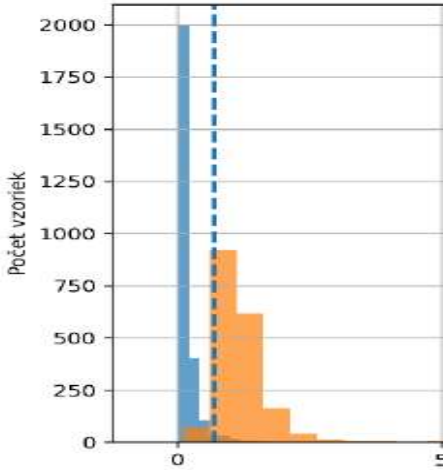
Abnormální obrázek
→ rekonstrukce není korektní
→ nalezení anomálie v rozdílovém obrázku

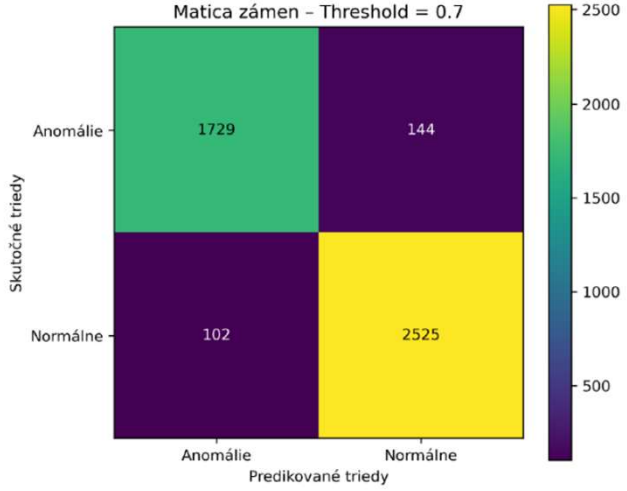
# MLP autoenkóder

**Príklad detekcie anomálie – Dataset ECG5000** (EKG normálne a patologické záznamy, vyrezané okná jedného úderu srdca)




| *Threshold* | Accuracy % | Precision % | Recall % | F1-score % |
|---|---|---|---|---|
| 0.0 | 41.62 | 41.62 | 100.0 | 58.78 |
| 0.7 | 94.53 | 94.43 | 92.31 | 93.36 |
| 1.0 | 82.16 | 94.96 | 60.33 | 73.78 |

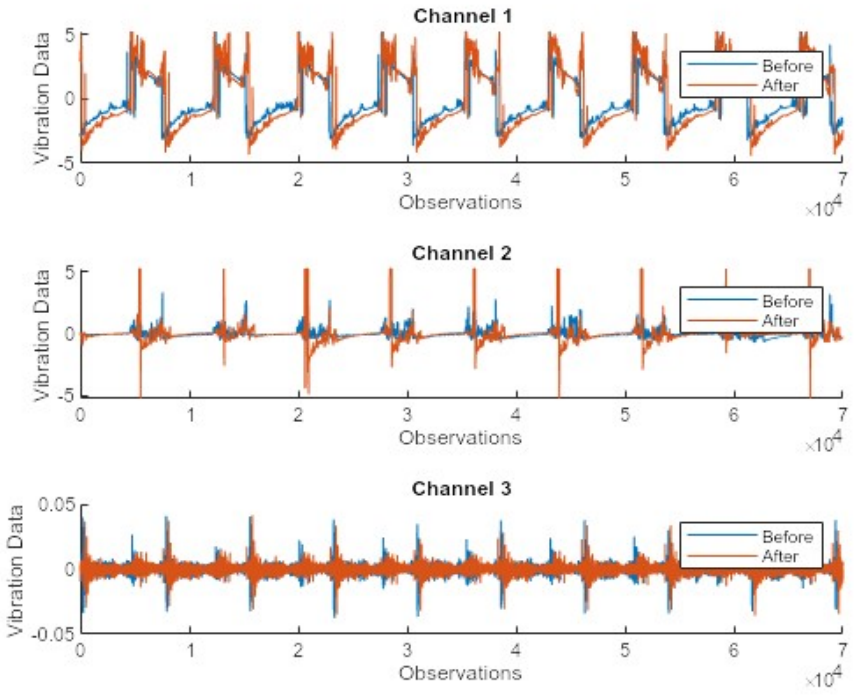


Detekcia anomálií pomocou autoenkodera – 3 osový senzor vibrácií

- Data pred servisom – abnormálne (before), data po servise (after) - normálne

- Výber príznakov z jednotlivých kanálov (min, max, mean, std, ...)
- Dostávame postupnosť príznakov pre autoencoder
- Autoencoder zostavený z LSTM vrstiev
- Trénovanie na normálnych dátach (after)
- Výpočet odchýlky vstupných a výstupných dát ,
- Nastavenie tresholdu pre detekciu anomálií




J. Jirkovský, Detekce anomálií, Prediktívna analytika a Vizuální inspekce, Humusoft, 2022,
https://www.mathworks.com/help/predmaint/ug/anomaly-detection-using-3-axis-vibration-data.html?searchHighlight=Detect%20Signal%20Anomalies&s_tid=srchtitle_Detect%2520Signal%2520Anomalies_10

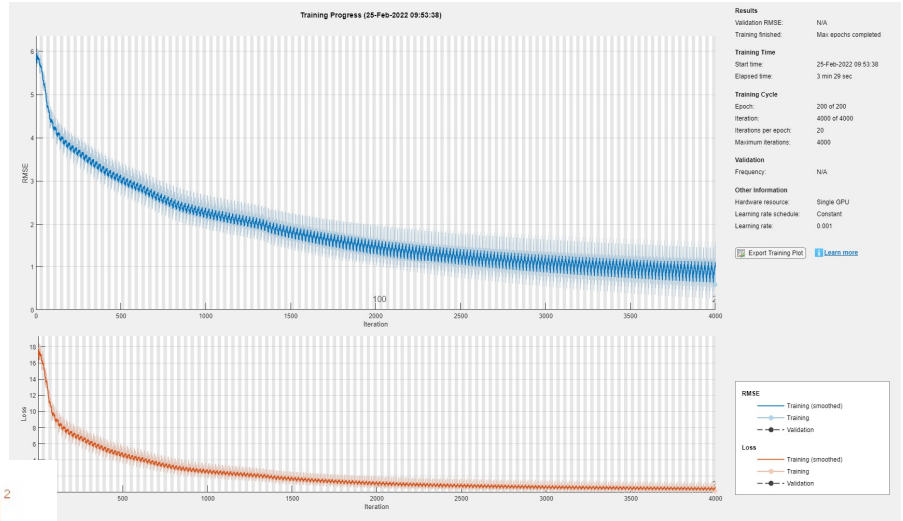
);

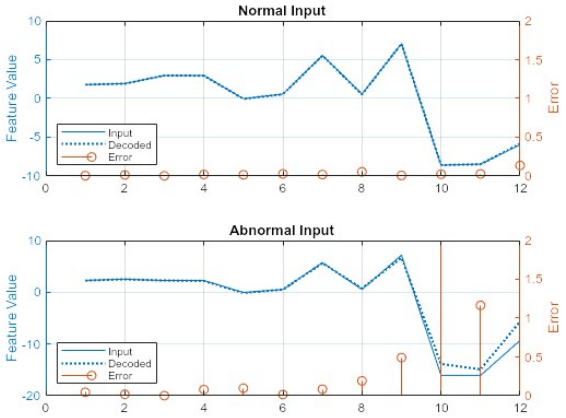
# Detekcia anomálií pomocou autoenkodera – 3 osový senzor vibrácií

- Data pred servisom – abnormálne (before), data po servise (after) - normálne

```
% Define biLSTM network layers
layers = [ sequenceInputLayer(featureDimension, 'Name', 'in')
   bilstmLayer(16, 'Name', 'bilstm1')
   reluLayer('Name', 'relu1')
   bilstmLayer(32, 'Name', 'bilstm2')
   reluLayer('Name', 'relu2')
   bilstmLayer(16, 'Name', 'bilstm3')
   reluLayer('Name', 'relu3')
   fullyConnectedLayer(featureDimension, 'Name', 'fc')
   regressionLayer('Name', 'out') ];

% Set Training Options
options = trainingOptions('adam', ...
   'Plots', 'training-progress', ...
   'MiniBatchSize', 500,...
   'MaxEpochs',200);
```



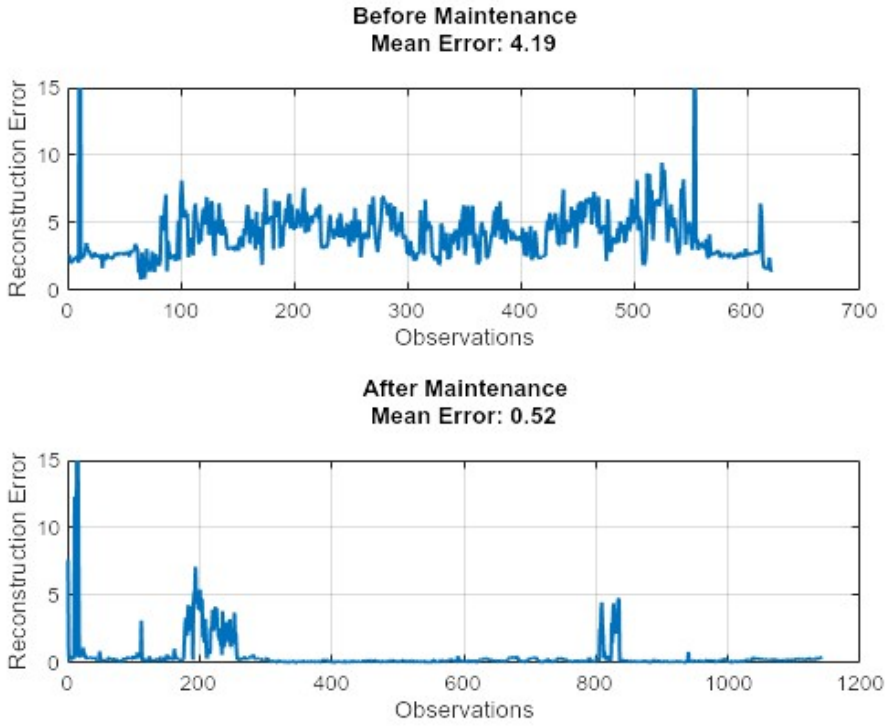



);

# Detekcia anomálií pomocou autoenkodera – 3 osový senzor vibrácií

- Data pred servisom – abnormálne (before), data po servise (after) - normálne

% Výpočet odchýlok pre normálne a abnormálne data




% Nastavenie tresholdu 0,5, výpočet úspešnosti

